

Rancangan Soal Varian dan Item Response Theory

Desain Numora untuk kualitas original dan varian serta Item Response Theory

Dokumen ini menjadi acuan kerja tim Product, Curriculum, Data/AI, Software, dan QA untuk membangun bank soal varian, menguji kualitasnya dari respons siswa, serta menjalankan penilaian IRT. Soal varian memiliki identitas dan riwayat sendiri; kelayakan konten, kualitas pengukuran, dan kesiapan distribusi diputuskan melalui gate yang berbeda.

IRT diprioritaskan untuk kualitas original, kesetaraan kandidat varian, monitoring kestabilan, dan self-adjusting configuration. Unit skala adalah bab–subbab–level. Pengumpulan dilakukan berurutan: original dahulu, kemudian original–varian. Theta digunakan secara internal untuk kalibrasi, sedangkan progres belajar dan placement tetap memakai rubrik serta mapping Curriculum.

Keputusan produk utama: Tryout digunakan untuk evaluasi latihan, ranking dalam batch, dan indikasi tren. Semua peserta dalam satu batch mengerjakan satu paket yang sama. Setelah penghitungan IRT atau penetapan fallback selesai, seluruh hasil dan pembahasan paket tersedia. Skor antarbatch tidak diklaim telah disetarakan pada satu master scale.

IRT adalah Item Response Theory. Model dan kebijakan di dokumen ini dapat berubah melalui keputusan produk yang tercatat dan berversi. Perubahan berikutnya harus menjelaskan dampaknya pada distribusi soal, kalibrasi, penilaian, dan hasil historis.

1 Keputusan desain yang berlaku

Area	Ketentuan
Pembuatan varian	Satu gelombang bank awal. Regenerate kandidat gagal termasuk perbaikan dalam gelombang itu. Gelombang penambahan stok berikutnya belum menjadi fitur.
Cold start	Pilot original lebih dahulu. Baseline original dan referensi diaktifkan setelah gate; baru kemudian A/B original–varian. Drill reguler tetap memakai original disahkan dan rubrik saat parameter belum tersedia.
Sumber uji	Drill memakai pilot original lalu trial A/B terkontrol dengan respons eligible. Tryout memakai respons paket operasional yang sama bagi seluruh peserta batch.
Model	PG memakai 2PL; PGK MCMA dan PGK Kategori memakai partial credit dan GPCM.
Ekosistem	Data dan parameter Drill serta Tryout dipisahkan. Theta internal Drill tidak digunakan sebagai prior personal atau penentu skor Tryout.
Dimensi	Drill memiliki skala independen per bab–subbab–level dan theta internal trial. Tryout memiliki satu theta_tryout global per peserta per batch.

Area	Ketentuan
Tujuan Tryout	Evaluasi latihan, ranking batch, indikasi tren; tanpa klaim equating kuat antarbatch.
Pembahasan Tryout	Seluruh item dibahas setelah hasil batch siap. Reference Anchor Bank dan reuse anchor tidak menjadi ketergantungan MVP Tryout.
Exposure	Dicatat per item versi, keluarga, dan pembahasan dari semua modul. Rencanakan cohort fase kedua sebelum pilot agar keluarga focal serta referensi belum terpapar.
Kualitas	Gate konten, peserta unik eligible, identifikasi, uncertainty, convergence, fit, kestabilan acuan, dan coverage. Discriminative Index menjadi QA pendamping.
Otomasi	Adjust dan regenerate dalam batas config dapat otomatis setelah evidence layak. Promosi item dan paket memiliki gate berbeda; anomaly masuk manual review.
Fallback dan histori	Drill reguler tetap dinilai dengan rubrik; trial belum layak ditahan. Tryout memakai fallback pada tenggat. Parameter baru tidak menimpa nilai atau XP historis.

Rubrik partial credit, parameter quality gate, toleransi original–varian, desain referensi, dan pemetaan theta ke skor Tryout membutuhkan konfigurasi yang disahkan. Bagian 18 menentukan pemilik, blocker, dan perilaku sistem selama konfigurasi tersebut belum tersedia. Tidak ada angka contoh dalam dokumen ini yang otomatis menjadi threshold produksi.

2 Arsitektur dan batas ekosistem

Satu IRT Engine menyediakan model 2PL dan GPCM, tetapi menerima konteks pengukuran secara eksplisit. Setiap permintaan membawa ecosystem, dimension, scoring_policy_version, response snapshot, serta scale_id atau batch_id. Pada Drill, scale_id mengikat bab, subbab, dan level; pada Tryout, konteksnya satu batch. Kesamaan kode engine tidak berarti data atau parameternya dapat dicampur.

Aspek	Drill dan Practice	Tryout
Tujuan	Menilai kualitas original–varian dan mendukung adjustment generator.	Evaluasi satu paket dan ranking peserta dalam batch.
Kemampuan	Theta internal per konteks trial; tanpa theta_profile bab pada MVP.	theta_tryout global untuk seluruh paket dalam batch.
Skala	Skala independen per bab–subbab–level; item dalam satu level perlu acuan yang terhubung.	Skala lokal setiap batch; tidak otomatis comparable antarbatch.

Aspek	Drill dan Practice	Tryout
Pola respons	Pilot original dahulu; A/B berikutnya untuk Compare. Drill reguler tetap latihan dengan pembahasan dan pengulangan.	Satu attempt per paket; paket sama untuk peserta batch.
Kalibrasi item	Kalibrasi awal original saja; setelah baseline serta referensi layak, A/B memakai acuan aktif.	Kalibrasi mixed format setelah batch ditutup.
Parameter lintas konteks	Parameter dan theta internal tidak disalin menjadi parameter Tryout.	Tidak menggantikan parameter lokal atau hasil belajar Drill.

Hubungan konten tetap boleh dicatat melalui keluarga soal yang sama. Namun, evidence kesetaraan dalam Drill hanya membuktikan hasil pada konteks Drill tersebut. Perpindahan item ke Tryout membawa kontennya, bukan kepastian bahwa parameter Drill berlaku pada skala global Tryout.

2 1 Tiga lapisan pemrosesan

1. Scoring mengubah jawaban mentah menjadi item_score, skor maksimum, dan penanda benar penuh sesuai rubrik versi yang digunakan.
2. IRT mengestimasi parameter item dan kemampuan dari item_score yang eligible dalam konteks pengukuran yang tepat.
3. Product memakai output IRT untuk keputusan kualitas original–varian, adjustment konfigurasi, analitik admin, dan skor Tryout. Profil belajar Drill memakai nilai, ketuntasan, progres, serta kompetensi. Nilai, XP, bintang, dan akses level tetap mengikuti aturan produk masing-masing.

Engine menyediakan antarmuka seperti estimate_theta, difficulty_summary, item_information, dan evaluate_item_quality. Output selalu menyertakan status, ketidakpastian, serta konteks skala. Aplikasi tidak perlu menafsirkan parameter mentah untuk menentukan kelayakan hasil.

3 Model IRT dan scoring policy

3 1 PG dengan model 2PL

PG memiliki skor salah atau kosong 0 dan benar 1. Model 2PL mengestimasi discrimination a, yaitu kekuatan hubungan respons item dengan kemampuan, dan difficulty b, yaitu posisi kesulitan pada skala kemampuan. Theta menyatakan kemampuan dalam dimensi dan konteks yang sedang diukur.

2PL mempertahankan variasi discrimination antaritem tanpa menambahkan parameter guessing. MVP tidak menghasilkan parameter tebakan seperti 3PL. Jika dashboard PRD menyebut tebakan, field tersebut ditandai tidak tersedia pada model MVP, bukan diisi angka default yang dianggap empiris. Pengembangan 3PL membutuhkan keputusan dan validasi baru.

3.2 PGK dengan model GPCM

PGK MCMA dan Kategori dapat menghasilkan skor kategori 0 sampai K. GPCM mengestimasi discrimination serta parameter langkah antar kategori skor. Contoh item maksimum 3 poin menerima kategori 0, 1, 2, dan 3; ini ilustrasi kategori, bukan keputusan rubrik MCMA Numora.

Rubrik harus memastikan skor lebih tinggi memberi evidence penguasaan yang lebih kuat. Curriculum menetapkan cara memperlakukan pilihan benar, pilihan salah, pernyataan kategori, respons kosong, dan jawaban tidak lengkap. Rubrik MCMA harus mengatasi strategi memilih semua opsi. Kategori yang jarang muncul, model fit, dan perilaku kurva skor diperiksa sebelum parameter diaktifkan. Urutan skor ordinal tidak berarti kemampuan antar kategori harus memiliki jarak yang sama.

Satu soal PGK diperlakukan sebagai satu unit psikometrik. Pernyataan atau opsi yang berbagi stimulus tidak otomatis dipecah menjadi item biner independen. GPCM mempertahankan skor parsial sebagai satu respons item. PG dan PGK dapat dianalisis dalam satu mixed-format model ketika asumsi dimensi dan data mendukungnya.

Tipe	Input ke IRT	Parameter item
PG	0 atau 1	a dan b
PGK MCMA	Kategori ordinal 0 sampai K	a dan parameter langkah kategori
PGK Kategori	Kategori ordinal 0 sampai K	a dan parameter langkah kategori

3.3 Kontrak rubrik dan perubahan versi

Setiap respons menyimpan jawaban mentah, `item_score`, `maximum_score`, `fully_correct`, dan `scoring_policy_version`. Skor kosong untuk item yang telah disajikan mengikuti rubrik; item yang tidak pernah disajikan adalah missing by design, bukan otomatis salah. Respons invalid atau sesi gagal tidak disamakan dengan respons salah.

Original dan varian yang dibandingkan harus memakai bentuk, kategori skor, serta rubrik yang kompatibel. Perubahan kunci, rubrik, jumlah kategori, atau isi penting menghasilkan versi baru dan memerlukan evaluasi kembali. Rubrik yang belum disahkan memblokir publikasi PGK terkait, sementara PG yang lengkap dapat tetap dipakai.

Nilai rubrik diperoleh dari poin item sesuai bobot yang disahkan dan dinormalisasi ke 0 sampai 100. Penggunaan partial credit untuk ketuntasan, bintang, dan XP harus ditentukan dalam kontrak scoring produk. Sela rentang bintang pada skor pecahan serta makna benar penuh perlu diselesaikan sebelum PGK dirilis; theta tidak digunakan untuk menutup sela tersebut.

4 Bank original dan varian

4.1 Identitas dan lineage

Original dibuat dan divalidasi Curriculum sebagai acuan kompetensi, bentuk, struktur penyelesaian, serta target kesulitan. Setiap keluarga memiliki `original_question_id` dan

family_id. Isi original terikat pada question_version_id yang tidak berubah setelah digunakan. Varian memiliki ID item dan versi tersendiri serta relasi ke versi original yang menjadi induknya.

Hubungan induk tidak membuat varian otomatis memiliki a, b, parameter langkah, atau status kalibrasi yang sama. Parameter selalu merujuk pada item versi, rubrik, ecosystem, dan scale atau batch tertentu. Revisi original tidak mengganti identitas induk pada varian historis.

4 2 Satu gelombang generasi

Tim menentukan daftar original, jumlah target varian, serta stok paket yang ingin disiapkan dalam satu generation_wave. Generator menghasilkan kandidat di luar permintaan siswa. Regenerate kandidat gagal adalah perbaikan dalam wave yang sama; kandidat lama tetap disimpan sebagai evidence. Penambahan stok melalui wave berikutnya belum menjadi fitur MVP.

Cold start dilakukan dalam dua fase. Fase pertama hanya menguji original yang telah lolos konten, mengestimasi kualitasnya, serta memilih referensi empiris yang layak. Setelah original focal dan reference set lokal lolos gate, baseline original serta parameter referensi dibekukan. Fase kedua baru mengumpulkan respons original–varian melalui A/B terkontrol dengan peserta baru yang eligible. Kandidat boleh disiapkan sebagai konten sebelum gate fase pertama selesai, tetapi belum boleh disajikan untuk pengumpulan respons varian.

Urutan ini wajib untuk setiap keluarga yang diuji. Pelaksanaan dapat bertahap per level dan keluarga: A/B untuk scope yang sudah layak boleh berjalan saat pilot original pada scope lain masih berlangsung. Tidak perlu menunggu seluruh 50 original lolos, tetapi original focal dan seluruh referensi eksperimen harus sudah memenuhi gate fase pertama pada skala lokal yang sama.

4 3 Pemisahan status

Status konten, pengukuran, perbandingan, dan distribusi disimpan pada field yang berbeda. Istilah READY tidak digunakan sendirian karena dapat menyamarkan apakah suatu item baru lolos konten, telah terkalibrasi, atau telah lolos kesetaraan. Status distribusi selalu mempunyai tujuan penggunaan dan konteks.

Lapisan	Status minimum	Makna operasional
Konten	DRAFT, CONTENT_VALID, REVIEW, QUARANTINED, ARCHIVED	Validasi akademik, kunci, pembahasan, dan kelayakan stimulus.
Pengukuran	UNCALIBRATED, INSUFFICIENT, CALIBRATION_FAILED, CALIBRATED, WATCH, DRIFT, ANOMALY	Kualitas parameter pada konteks scale atau batch tertentu.
Perbandingan	PENDING, INSUFFICIENT, PASS, DRIFT, NOT_COMPARABLE, ANOMALY	Kesetaraan kandidat terhadap baseline eksperimen yang spesifik.
Distribusi	PROVISIONAL, READY, HOLD, RETIRED	Boleh dipilih oleh assembler untuk tujuan yang ditentukan.

Commented [NP1]: Keputusan 2 Oktober 2026: original dahulu, kemudian original–varian. Respons kandidat menunggu kualitas original dan referensi; menggantikan cold start A/B bersama.

PROVISIONAL berarti konten valid dan rubrik tersedia, tetapi evidence empiris belum cukup. Untuk kandidat baru Drill, izin trial juga mensyaratkan original focal mempunyai baseline layak dan reference set aktif dari fase pertama; validasi konten saja belum membuka pengumpulan respons kandidat. Original yang disahkan Curriculum tetap dapat dipakai sebagai bank awal berbasis rubrik. Promosi varian ke READY produksi membutuhkan gate konten, pengukuran, dan Compare; pakatnya juga harus lolos gate paket. Kelayakan satu konteks tidak otomatis memberi READY pada ekosistem lain.

5 Generator dan validasi kandidat

Generator hanya mengubah parameter yang diizinkan Curriculum: angka, konstanta, variabel, nama atau konteks, serta opsi dan distractor dalam batas template. Kompetensi, bentuk, rubrik, struktur penyelesaian, dan batas kesulitan yang ditargetkan tetap menjadi constraint. Perubahan yang melampaui batas masuk review sebagai konten baru.

- Kandidat menyimpan seed, template_version, generator_config_version, nilai parameter aktual, variant_version, serta parent_question_version_id.
- Validasi statis memeriksa solusi, kunci, opsi unik, jumlah jawaban benar, domain angka, satuan, stimulus, dan konsistensi pembahasan terhadap nilai yang dihasilkan.
- Konten yang identik atau berbeda hanya karena urutan opsi dideteksi sebagai duplikat substantif. Perubahan ID tidak menciptakan exposure baru.
- Pembahasan dibuat untuk nilai dan opsi kandidat tersebut. Sistem tidak menyalin pembahasan original yang sudah tidak sesuai.

Template dan ruang konfigurasi harus disahkan Curriculum sebelum dapat dipublikasikan otomatis. Untuk template deterministik dengan pemeriksaan lengkap, kandidat di dalam ruang tersebut dapat melanjutkan gate tanpa review manual per item. Kandidat yang dibuat AI bebas, ambigu, atau tidak dapat diverifikasi secara otomatis tetap membutuhkan review Curriculum. Gate ini menentukan kapan pilihan auto-publish dapat berlaku.

Seed dan versi konfigurasi mendukung reproduksi, tetapi payload item, kunci, dan pembahasan yang benar-benar disajikan tetap disimpan sebagai snapshot. Perubahan kode generator tidak boleh mengubah konten historis ketika seed lama dijalankan kembali.

6 Pengumpulan respons dan exposure

Pada Drill, fase pertama memakai pilot original; fase kedua memakai trial A/B sebagai sumber utama Compare. Keduanya menggunakan engine sesi yang sama dengan package_type dan phase_id terpisah. Respons Drill reguler yang layak dapat menjadi monitoring tambahan, tetapi tidak otomatis digabung dengan trial. Tryout dapat memuat kandidat valid dalam paket yang sama untuk semua peserta; quality gate IRT menentukan apakah respons item tersebut layak menyumbang skor batch setelah periode ditutup.

6.1 Pilot original

Pilot original memakai cohort terbatas dengan coverage sasaran yang ditetapkan. Original dan calon referensi telah lolos validasi konten; belum ada kandidat varian dalam paket. Jika 50 original dibagi ke beberapa paket, rencanakan item bersama serta alokasi responden

agar skala lokal terhubung. Data respons menentukan kelayakan original, bukan sekadar jumlah submit.

Sebelum pilot, rencanakan sumber cohort fase kedua yang belum terpapar keluarga focal dan calon referensi. Jangan memberikan seluruh 50 original kepada semua calon peserta A/B. Gunakan cohort terpisah atau pembagian keluarga yang menjaga eligibility paket; kebutuhan sampel dihitung per item dan fase. Bank item serta assignment untuk cohort yang disiapkan harus mencegah paparan keluarga terkait dari pretest, Drill, PvP, Tryout, dan pembahasan. Jika ini tidak dapat dijaga, rekrut peserta baru atau tunda A/B; peserta pilot tidak dianggap bersih kembali hanya karena jeda waktu.

6 2 Pelaksanaan trial A dan B

Pada fase kedua, peserta baru eligible diacak 1:1 ke A atau B di dalam kelas dan periode yang sama, dengan assignment yang disimpan permanen per eksperimen. Refresh dan resume mempertahankan arm serta paket yang sama. Satu peserta hanya menjalani satu arm; pola A terlebih dahulu lalu B sebagai retry tidak digunakan. Pengacakan mengurangi bias seleksi, tetapi tidak menjamin kemampuan kelompok identik. Model menggunakan referensi lokal aktif dan mengakomodasi perbedaan distribusi kemampuan kelompok.

A berisi referensi aktif dan original focal yang lolos fase pertama; B berisi referensi identik dan kandidatnya. Kedua arm memakai versi referensi, rubrik, blueprint, waktu, instruksi, serta posisi penyajian yang setara. Contoh paket 10 soal memakai sembilan referensi dan satu focal; angka sembilan adalah ilustrasi, bukan ketentuan minimum anchor. Referensi berasal dari keluarga lain pada level yang sama; original dan variannya tidak disajikan bersama kepada satu peserta.

Bekukan konten, seed, config version, dan snapshot paket sebelum pengumpulan. Banyak peserta menjawab kandidat versi yang sama; generator tidak membuat angka kandidat baru untuk setiap peserta trial. Prioritaskan beberapa keluarga dan kandidat aktif, bukan menguji seluruh stok serentak. Distribusi target kelas, periode, dan coverage kemampuan ditetapkan sebelum trial.

Pilot original dan trial A/B memakai engine sesi yang sama dengan penanda uji soal yang terlihat oleh peserta. Keduanya tidak memberikan XP, bintang, mastery, unlock, atau nilai latihan utama. Pembahasan uji dibuka setelah pengumpulan batch terkait ditutup agar tidak mencemari evidence peserta berikutnya. Penutupan pilot tidak membuat pesertanya kembali eligible untuk keluarga yang telah dikerjakan. Aturan pembahasan Drill reguler setelah submit dan akses 90 hari tetap berlaku.

Simpan jumlah assigned, started, completed, eligible, dan excluded per fase; pada fase kedua, laporkan juga per arm. Catat alasan dropout serta jumlah responden unik per item. Pemeriksaan keseimbangan menggunakan kelas, periode, dan variabel awal yang tersedia tanpa membuat theta bab baru. Ketimpangan completion, coverage yang sempit, atau perubahan kondisi pelaksanaan menahan keputusan. Jangan memindahkan peserta antararm untuk memperbaiki angka hasil.

6 3 Evidence yang diterima

Evidence	Kalibrasi dan uji kesetaraan	Riwayat dan progres
----------	------------------------------	---------------------

Commented [NP2]: Cohort fase kedua perlu direncanakan sebelum pilot. Exposure original maupun calon referensi dari semua modul menentukan eligibility, bukan hanya apakah pernah mengikuti pilot.

Evidence	Kalibrasi dan uji kesetaraan	Riwayat dan progres
Pilot atau A/B selesai dan valid; first exposure seluruh keluarga yang disajikan	Pilot: kalibrasi original dan calon referensi. A/B: Compare dengan original kontrol baru dan acuan aktif; dataset fase terpisah.	Trial tercatat terpisah; tanpa XP, mastery, atau unlock.
Pernah mengerjakan keluarga atau membuka pembahasan	Tidak masuk subset bersih trial untuk keluarga tersebut; alasan tetap tersimpan.	Drill reguler tetap dapat menjadi aktivitas belajar.
Attempt ulang pada item yang sama	Tidak dihitung sebagai responden unik eligible baru.	Retry trial bukan evidence baru; latihan reguler mengikuti PRD.
Sesi invalid, cancelled, atau duplikat	Dikeluarkan dari dataset pengukuran.	Tidak menghasilkan penilaian final ganda.

Pilot menerima first exposure pada keluarga original yang disajikan. Untuk A/B, peserta belum pernah terpapar keluarga focal original–kandidat maupun seluruh keluarga referensi dalam paketnya. Peserta pilot yang pernah mengerjakan salah satu keluarga tersebut tidak eligible untuk eksperimen A/B terkait; tidak ada larangan global mengikuti uji keluarga lain yang benar-benar belum terpapar. Riwayat dari semua modul dan akses pembahasan diperiksa sebelum assignment serta dikunci dalam eligibility snapshot. Perubahan ID atau urutan opsi tidak memulihkan eligibility.

Sesi cancelled, invalid, submit duplikat, dan exposure ulang dikeluarkan dari dataset utama melalui policy berversi. Jawaban salah dari peserta eligible tetap digunakan; exclusion tidak didasarkan pada benar atau salahnya jawaban. Item yang tidak disajikan adalah missing by design; omission pada item yang telah disajikan mengikuti scoring policy yang dibekukan. Evidence mentah dan exclusion reason tetap tersimpan untuk audit.

Sistem mencatat exposure dari semua modul, termasuk pretest dan PvP. Respons modul tersebut tidak otomatis ditambahkan ke kalibrasi Drill atau Tryout; catatan exposure-nya tetap digunakan untuk menilai kebersihan respons berikutnya. Aktivitas di luar platform tidak seluruhnya dapat diamati, sehingga status bersih menyatakan kelayakan berdasarkan evidence yang tersedia.

Unit evidence Drill adalah respons item versi dari sesi uji valid dalam window dan fase pengumpulan yang ditentukan. Fase pertama menghasilkan dataset kalibrasi original; fase kedua menghasilkan dataset Compare A/B tersendiri. Data pilot menjadi sumber baseline dan referensi, bukan pengganti respons original kontrol pada fase kedua. Kemampuan internal merujuk episode pengukuran, bukan satu theta tetap sepanjang histori siswa. Data trial dan monitoring operasional tidak otomatis dipool; penggabungan memerlukan policy konteks, periode, exposure, dan ketergantungan peserta yang disahkan.

7 Kalibrasi item dan quality gate

7 1 Gate sebelum parameter digunakan

Minimum 30 responden unik eligible per item versi pada PRD adalah batas awal analisis, bukan jaminan parameter stabil atau kandidat lulus. Original, kandidat, dan setiap referensi mempunyai hitungan masing-masing; jumlah jawaban berulang tidak menggantikan jumlah responden. Status CALIBRATED juga membutuhkan convergence, identifikasi skala, ketidakpastian yang memadai, sebaran respons, kategori skor yang cukup teramati, model fit, serta pemeriksaan anomaly.

- Data dan versi konsisten; tidak ada campuran kunci, rubrik, atau konten yang berbeda dalam satu item.
- Graf respons dan item bersama atau reference set mendukung identifikasi satu skala lokal. Coverage kemampuan dan kestabilan acuan diperiksa; subset yang terputus tidak dipaksa menjadi satu penggaris hanya karena label levelnya sama.
- Estimasi converged, parameter tidak berada pada batas yang mencurigakan, dan ketidakpastian dapat dihitung atau dinilai dengan metode yang disahkan.
- GPCM memiliki evidence kategori yang memadai. Kategori kosong tidak otomatis digabung karena penggabungan mengubah rubrik dan versi.
- Unidimensionalitas dan ketergantungan lokal dievaluasi. Model global Tryout adalah asumsi pengukuran yang perlu diperiksa, bukan jaminan bahwa semua bab identik.

Data yang belum memadai menghasilkan INSUFFICIENT. Estimasi gagal menghasilkan CALIBRATION_FAILED. Keduanya tidak memicu adjustment generator seolah telah terbukti ada drift. Parameter empiris tetap kosong atau disimpan sebagai estimate diagnostik yang belum aktif.

7 2 Skala lokal Drill

Pilihan D memakai skala independen untuk setiap kombinasi chapter_id, subchapter_id, dan level_id. Lima level pada satu subbab memiliki lima scale_id berbeda. Original dan varian dalam level yang sama harus dihubungkan oleh desain kalibrasi yang layak. Theta dan difficulty antarlevel atau antarsubbab tidak dibandingkan langsung, dirata-ratakan, atau digabung menjadi theta_profile per bab.

Kalibrasi awal pada fase pertama hanya memakai original. Calon referensi berasal dari original tersebut dan belum mempunyai parameter empiris aktif. Paket pilot dapat dibagi menurut blueprint lokal; jika ada beberapa paket, item bersama dan graf respons harus menghubungkan seluruh item yang hendak memakai satu scale_id. Identifikasi skala, coverage kemampuan, precision, fit, kategori GPCM, serta ketergantungan lokal diperiksa. Pilih reference set yang memberi informasi memadai pada rentang kemampuan sasaran dan lolos pemeriksaan kestabilan. Sebutan original tidak otomatis membuktikan kualitas pengukuran atau kelayakan menjadi referensi.

Setelah fase pertama lolos gate, simpan baseline original, reference_set_version, parameter referensi, dan calibration_version sebagai acuan lokal berversi. Pada fase kedua, parameter referensi dipasang tetap untuk mengestimasi kandidat dan original kontrol pada koordinat yang sama; original kontrol tetap diestimasi dari respons A agar perubahan terhadap baseline dapat terdeteksi. Distribusi kemampuan kelompok boleh berbeda. Uncertainty baseline dan referensi tetap dipertimbangkan dalam evaluasi; pembekuan bukan kepastian tanpa error.

Monitoring dan pemeriksaan sensitivitas menjaga kestabilan acuan. Drift menahan Compare serta auto-adjust; pergantian referensi harus terhubung ke skala aktif dan berversi.

Gate fase pertama memisahkan kekurangan data dari masalah original. INSUFFICIENT menahan pembekuan sambil menambah evidence; CALIBRATION_FAILED memicu pemeriksaan model atau data. Salah kunci, ambiguity, atau misfit yang belum selesai menahan keluarga terkait dan review Curriculum/Data/AI. Original yang direvisi memakai versi baru, dataset baru yang eligible, serta baseline baru; data versi berbeda tidak dipool. Reference set yang belum layak menahan seluruh eksperimen yang bergantung padanya.

Original yang dipakai sebagai referensi boleh memiliki varian. Ketika varian dari original tersebut diuji, pilih referensi dari keluarga lain yang sudah berada pada skala lokal yang sama. Referensi bukan keluarga permanen tanpa varian. Pool referensi dan kebutuhan peserta baru perlu direncanakan karena setiap paparan mengurangi populasi yang eligible pada trial berikutnya.

Skala lokal yang sempit atau respons hampir semuanya benar maupun salah dapat kekurangan informasi, terutama untuk discrimination. Jika original, kandidat, atau referensi belum memenuhi precision dan coverage, tambah evidence yang sesuai atau review desain; jangan memaksa label CALIBRATED hanya karena 30 peserta tercapai.

7 3 Skala lokal Tryout

Setiap batch Tryout membentuk model global sendiri dari dataset batch yang telah dikunci. Skala dapat diidentifikasi dengan distribusi referensi batch yang ditetapkan oleh prosedur kalibrasi. Identifikasi mean 0 dan SD 1 pada masing-masing batch tidak membuat batch tersebut otomatis setara dengan batch lain.

MVP tidak membutuhkan Reference Batch, Reference Anchor Bank, rotation, cooldown, fixed-anchor linking, atau kelompok pilot khusus. Kemunculan soal yang sama pada beberapa batch hanya dicatat sebagai common item dan exposure; item tersebut tidak otomatis digunakan sebagai anchor untuk menyatakan skor sudah disetarakan.

Filter exposure menentukan evidence yang boleh masuk kalibrasi, bukan paket atau daftar item penilaian yang berbeda untuk tiap siswa. Setelah parameter batch layak, semua attempt valid dinilai memakai daftar item berkontribusi yang sama. Jika subset kalibrasi bersih terlalu kecil, batch memakai fallback. Ranking latihan tetap dapat dipengaruhi pengalaman terhadap keluarga soal; konteks ini dicatat pada interpretasi hasil.

8 Perbandingan original dan varian

8 1 Kontrak perbandingan

Eksperimen Compare hanya dibuka setelah gate fase pertama untuk original focal dan reference set lokal terpenuhi. Simpan source_original_calibration_id, versi original, kandidat, baseline parameter, reference set, model, rubrik, ecosystem, scale_id, dataset snapshot, dan tolerance_version. Baseline serta parameter referensi dibekukan sepanjang eksperimen; original kontrol diestimasi ulang pada fase kedua. Parameter hanya dibandingkan pada koordinat yang kompatibel. Sebelum baseline siap, Compare tetap PENDING dan respons kandidat belum dikumpulkan.

Commented [NP3]: Baseline dibekukan setelah fase pertama. Pada fase kedua referensi fixed, sementara original kontrol diestimasi ulang agar drift baseline dapat diperiksa.

Commented [NP4]: Data kurang dan original bermasalah mempunyai tindakan berbeda. Tidak ada auto-adjust kandidat terhadap baseline yang belum layak.

Model	Metrik utama	QA pendamping
2PL	Selisih difficulty dan discrimination; perilaku kurva respons pada rentang kemampuan sasaran.	SE atau interval, model fit, Discriminative Index, kualitas opsi.
GPCM	Discrimination, parameter langkah, serta kurva skor harapan yang dinormalisasi terhadap skor maksimum.	SE atau interval, frekuensi kategori, model fit, QA distractor atau pernyataan.

Untuk PG, selisih b kandidat terhadap b original menunjukkan arah perubahan kesulitan pada skala yang sama. Selisih atau rasio a menunjukkan perubahan discrimination sesuai comparison policy. Untuk PGK, ringkasan difficulty saja tidak membuktikan kesetaraan; parameter langkah dan kurva skor harapan yang dinormalisasi juga diperiksa. Evaluasi memakai rentang theta dan bobot sasaran yang sama, serta uncertainty kedua estimasi.

Discriminative Index memiliki definisi yang disimpan berversi. Contohnya, selisih proporsi benar kelompok kemampuan tinggi dan rendah pada PG; pada PGK dapat memakai skor parsial yang dinormalisasi. Komposisi kelompok memengaruhi metrik tersebut, sehingga selisih D antar cohort bukan bukti drift yang berdiri sendiri.

8.2 Keputusan Compare

Hasil	Kondisi	Tindakan
PASS	Baseline original telah lolos fase pertama; gap dan uncertainty memenuhi toleransi; konten, model, original kontrol, serta referensi layak.	Luluskan item sesuai gate; gate paket tetap terpisah.
DRIFT	Evidence cukup menunjukkan gap material; baseline dan reference set stabil.	Adjust config pada keluarga dan level terkait lalu regenerate.
INSUFFICIENT	Sample, precision, atau coverage belum memadai.	Kumpulkan evidence; jangan adjust karena noise.
NOT_COMPARABLE	Skala, reference set, bentuk, rubrik, atau konteks tidak kompatibel.	Tahan klaim kesetaraan; jangan hitung gap a atau b lintas skala.
ANOMALY	Indikasi salah kunci, ambiguity, kualitas data, atau respons tidak wajar.	Quarantine dan manual review.

Interval terlalu lebar menghasilkan INSUFFICIENT, bukan PASS hanya karena point estimate terlihat dekat. Toleransi ditetapkan sebelum trial dan divalidasi Data/AI bersama Curriculum. Setiap trial fase kedua, termasuk A/B pertama, memeriksa original kontrol terhadap baseline. Jika original atau referensi tidak stabil, tahan keputusan untuk review konteks, acuan, dan data; jangan menyimpulkan drift kandidat atau melakukan auto-adjust.

8.3 Penerapan pada masing-masing ekosistem

Pada Drill, cold start mengikuti Validasi original, Pilot original, Kalibrasi original, Gate baseline dan referensi, lalu Validasi kandidat, Uji A/B, dan Compare pada skala bab–subbab–level. Siklus kandidat berikutnya memakai acuan aktif: Uji, Compare, Adjust bila evidence cukup, dan Regenerate. Pengujian varian tidak dimulai bersamaan dengan pilot original. Pengulangan keluarga tidak dihitung sebagai respons independen yang menggelembungkan evidence.

Pada Tryout, original di Batch A dan varian di Batch B berada pada skala lokal berbeda. Compare langsung terhadap a, b, atau parameter langkah lintas batch diberi status NOT_COMPARABLE. Parameter Drill juga tidak digunakan untuk menjembatani perbedaan ini. MVP mengevaluasi validitas konten dan kualitas item pada batchnya; hasil tersebut disimpan sebagai TRYOUT_QUALITY_PASS, bukan bukti kesetaraan empiris terhadap original.

Memasukkan original dan varian dekat ke satu paket yang dikerjakan semua siswa bukan jalan pintas untuk membuktikan kesetaraan. Paparan pertama dapat memberi petunjuk untuk item berikutnya dan menimbulkan ketergantungan lokal. Assembler menghindari keluarga dekat dalam satu paket. Klaim kesetaraan Tryout lintas batch memerlukan desain penelitian atau linking tambahan di luar scope saat ini.

9 Adjustment dan publikasi otomatis

MVP memakai rule-based adjuster yang transparan. Adjustment hanya terjadi setelah evidence kompatibel cukup kuat, original layak, dan acuan stabil. Original bermasalah diperiksa atau direvisi lebih dahulu; generator tidak diarahkan meniru salah kunci atau misfit original. Numeric complexity, peluang pecahan atau negatif, operation count, wording, dan distractor disesuaikan di dalam batas template serta keluarga pada level yang sama. Keputusan pada satu keluarga atau skala tidak otomatis mengubah konfigurasi semua level. Parameter historis kandidat gagal tidak diubah untuk membuat hasilnya terlihat lolos.

1. Evaluator menghasilkan keputusan beserta evidence, uncertainty, dan alasan gate.
2. Adjuster memilih perubahan terbatas yang memang diizinkan Curriculum. Batas perubahan ditentukan per parameter; contoh 10 sampai 20 persen bukan aturan universal.
3. Sistem membuat generator_config_version baru, menggunakan seed baru, dan menghasilkan kandidat pengganti dengan lineage eksperimen yang sama.
4. Kandidat baru menjalani validasi statis dan gate konten. Pada Drill, versi ini diuji dalam trial baru dengan peserta yang belum terpapar keluarga focal dan referensinya. Respons versi lama tidak dipool sebagai evidence versi baru, dan parameter tidak diwariskan dari original atau kandidat sebelumnya.
5. Evaluasi diulang. Kandidat Drill yang lolos konten, pengukuran, dan Compare dapat dipromosikan untuk konteksnya; paket produksi memerlukan gate terpisah. Publikasi otomatis hanya berlaku bila seluruh gate penggunaan lolos. Jika gate belum dapat diperiksa, kandidat tetap PROVISIONAL untuk trial atau HOLD sesuai alasan, bukan READY produksi.

Rekomendasi awal adalah maksimum lima regenerate otomatis sebelum manual review; angka ini dicatat sebagai max_regenerate_attempts dan disahkan bersama konfigurasi generator sebelum otomasi aktif. Setiap iterasi mempunyai kondisi penghentian: PASS, insufficient data,

skala tidak kompatibel, anomaly, atau batas konfigurasi tercapai. Dengan demikian pilihan auto-publish tidak menghasilkan loop tanpa batas.

Pada model yang membatasi a positif, pola respons yang berlawanan dengan kemampuan tidak akan terlihat sebagai nilai a negatif. Korelasi item dengan kemampuan yang berlawanan, corrected item-total negatif, a mendekati nol, misfit, atau kegagalan estimasi memicu pemeriksaan. Indikasi salah kunci menghentikan auto-adjust; sistem tidak sekadar mengubah angka agar metrik terlihat membaik.

Untuk Tryout, keputusan lintas batch NOT_COMPARABLE tidak boleh memicu rule seperti b terlalu tinggi dibanding original. Temuan kualitas dalam batch dapat menghasilkan usulan perbaikan konten atau konfigurasi yang sah, tetapi tidak dipromosikan sebagai keberhasilan kesetaraan lintas batch. Kandidat pengganti tetap diuji sebagai item baru pada penggunaan berikutnya.

Recalibration original membuat versi baseline baru. Eksperimen yang sedang berjalan menyelesaikan atau dihentikan secara eksplisit terhadap baseline lamanya; eksperimen baru merujuk baseline baru. Evidence varian lama tetap dapat dibaca bersama versi baseline yang dulu digunakan.

10 Penyusunan paket dan distribusi

10.1 Paket Drill

Paket Drill reguler mematuhi bab, subbab, level, kompetensi, bentuk, serta jumlah 10 soal per sesi pada baseline PRD. Paket mengambil item dari bank tersimpan: original tervalidasi untuk cold start, atau varian yang sudah lolos gate produksi. Siswa yang mengulang memperoleh variasi berbeda sesuai ketersediaan, sedangkan refresh atau resume memakai snapshot paket yang tersimpan pada attempt yang sama. Paket trial mempunyai package_type dan assignment terpisah dari indeks varian produksi.

Gate paket produksi memeriksa coverage kompetensi, komposisi item, jumlah soal, kategori skor, exposure, dan profile expected score pada rentang kemampuan sasaran. Jika paket dinyatakan setara dengan paket original, evaluasi juga perubahan peluang mencapai nilai rubrik 80 persen melalui metode serta toleransi yang divalidasi. Semua item PASS belum otomatis membuat paket READY; ketergantungan lokal tetap diperiksa.

Paket produksi dapat berisi seluruhnya varian yang telah lolos; soal referensi trial tidak wajib muncul dalam setiap paket belajar. Status READY paket menyimpan blueprint, daftar item versi, comparison_policy_version, dan evidence paket tersendiri. Klaim setara empiris hanya diberikan ketika gate tersebut lolos.

Untuk stok varian produksi, assembler memprioritaskan varian yang belum pernah dilihat siswa. Jika seluruh varian tersedia pernah dilihat, assembler dapat merotasi stok lama yang berbeda dari attempt terakhir dan menandainya sebagai exposure ulang; klaim fresh atau evidence exposure pertama tidak diberikan. Jika stok tidak dapat memenuhi perubahan paket, attempt baru ditahan dengan status stok varian belum tersedia. Sistem tidak melakukan generasi mendadak di luar generation_wave.

Pemilihan stok tidak mengubah versi paket di tengah sesi. Item yang di-quarantine setelah sesi dimulai ditangani melalui kebijakan insiden, bukan diganti diam-diam untuk sebagian siswa. Attempt, skor, dan XP diproses idempotent agar submit berulang tidak menggandakan hasil.

10 2 Paket Tryout

Paket baru mengikuti rilis mingguan Senin 00.00 WIB pada PRD. Sebelum rilis, paket, urutan atau aturan penyajian, rubrik, parameter penilaian produk, serta daftar item versinya dibekukan. Seluruh peserta dalam batch menerima daftar item yang sama. Tidak ada A/B testing paket, blok tambahan khusus sebagian peserta, atau pergantian kandidat berdasarkan histori theta profil.

Pemilihan mengutamakan soal yang belum dirilis pembahasannya kepada peserta sasaran. Original atau varian satu keluarga dekat yang sudah tersebar di Drill juga diperiksa sebagai exposure. Perbedaan ID tidak cukup untuk menjamin freshness. Soal yang telah dibahas tidak diperlakukan sebagai anchor aman untuk batch berikutnya.

Jika stok tidak memenuhi blueprint, validasi konten, atau aturan exposure paket, rilis mendapat status NO_READY_PACKAGE dan perlu tindakan Product serta Curriculum. Sistem tidak diam-diam mengulang paket lama untuk mengejar jadwal. Horizon stok dan kebijakan reuse sebagai latihan ulang harus disahkan terpisah; penambahan wave kedua belum diimplementasikan.

Pretest dan PvP boleh memakai konten yang diizinkan masing-masing modul, tetapi tidak menjadi sumber kalibrasi campuran secara default. Semua pemakaian tetap menambah exposure ledger. Publikasi ke modul lain tidak boleh membuka item yang sedang disiapkan sebagai soal fresh Tryout tanpa evaluasi ulang.

11 Implementasi IRT pada Drill

11 1 Cold start dan parameter item

Sebelum data cukup, sistem memakai label difficulty Curriculum serta nilai dan mastery berbasis rubrik. Field parameter empiris dan theta IRT tetap kosong atau berstatus belum tersedia. Nilai teknis a sama dengan 1 atau b sama dengan 0, bila dibutuhkan algoritma internal, tidak dicatat sebagai hasil kalibrasi empiris.

Eligibility diperiksa harian. Checkpoint fase pertama mengkalibrasi original dan menentukan kesiapan baseline serta referensi; checkpoint fase kedua mengestimasi A/B dan menjalankan Compare. Jadwal serta kriteria ditetapkan sebelum pengumpulan setelah tambahan evidence memadai. Monitoring original, referensi, dan item produksi dilakukan berkala pada skala bab-subbab-level. Estimasi monitoring tidak langsung mengganti parameter aktif; aktivasi versi baru memerlukan gate kestabilan dan pemeriksaan dampak pada item serta paket.

11 2 Siklus kualitas original dan varian

1. Validasi original, lalu bekukan versi konten, rubrik, blueprint pilot, sampling policy, dan target respons. Tetapkan cohort pilot serta sumber peserta baru fase kedua sebelum original atau calon referensi tersebar ke mereka.
2. Kumpulkan respons original saja. Simpan jawaban mentah, item_score, exposure, missing atau omission, completion, dan exclusion tanpa menghapus evidence mentah. Kalibrasi original pada checkpoint sesuai quality gate.

Commented [NP5]: Workflow dan kontrak data membedakan pilot original serta A/B. Tahap kedua memerlukan sumber kalibrasi original dan keputusan gate yang dapat diaudit.

3. Aktifkan baseline original dan reference set hanya untuk scope yang lolos konten, kualitas pengukuran, coverage, precision, dan kestabilan. Evidence kurang menambah pengumpulan; anomaly atau misfit memicu review. Revisi konten menghasilkan versi baru yang diuji kembali sebelum menjadi baseline.
4. Setelah gate fase pertama terpenuhi, validasi kandidat dan bekukan seed, config, paket A/B, versi baseline, referensi, serta tolerance policy. Rekrut peserta baru yang eligible untuk seluruh keluarga pada paket, lalu simpan assignment 1:1 dalam kelas dan periode.
5. Estimasi original kontrol dan kandidat dengan parameter referensi aktif tetap. Periksa kompatibilitas skala, uncertainty, dropout, serta kestabilan original kontrol dan referensi sebelum menilai gap original–varian.
6. Compare memberi PASS, DRIFT, INSUFFICIENT, NOT_COMPARABLE, atau ANOMALY. PASS melanjutkan gate produksi item dan paket; DRIFT dengan evidence cukup melanjutkan adjustment terbatas dan regenerate. Kandidat pengganti diuji lagi dengan peserta eligible baru. Status lain menahan otomasi sesuai alasan.

Setiap kandidat mempunyai seed, content version, dan config version tetap selama trial agar banyak peserta menjawab item yang sama. Respons peserta yang sudah melihat keluarga tidak menjadi evidence baru untuk regenerate berikutnya. Lulusnya satu kandidat tidak membuktikan semua seed atau seluruh ruang generator setara; keluaran lain tetap menjalani validasi dan evidence yang diperlukan.

Theta tetap menjadi variabel internal model untuk memisahkan kemampuan peserta dari karakteristik soal. Bila disimpan, gunakan snapshot dengan `experiment_id`, `scale_id`, `model_version`, dan `uncertainty`. MVP Drill tidak menjalankan `update_theta_profile` per bab setelah setiap sesi, prior profil longitudinal, reconciliation theta bab, atau placement berbasis gabungan theta lokal.

11.3 Output produk

Analitik siswa dan guru memakai level terbuka atau selesai, nilai terakhir dan terbaik, ketuntasan, mastery, kompetensi, serta pola kesalahan yang disahkan. Strength map dan class profile tidak menggabungkan atau merata-ratakan theta lokal dari level berbeda. Label difficulty Curriculum mengatur struktur belajar; difficulty empiris terutama membantu admin pada konteks levelnya. Ringkasan GPCM selalu mempunyai definisi serta versi dan tidak dianggap satu b 2PL tanpa konteks.

Ketuntasan Drill tetap mengikuti ambang 80 persen dari nilai rubrik; bintang dan XP mengikuti policy produk. Pretest tetap opsional, sekali per bab, dengan 20 soal dari berbagai level dan mapping Curriculum untuk placement. Batas maksimal tiga level awal per subbab mengikuti ketentuan PRD; hasil pretest tidak membutuhkan skala theta lintas level. Level terbuka tidak dikunci kembali karena perubahan estimasi IRT. Semua penggunaan pretest tetap menambah exposure ledger.

12 Implementasi IRT pada Tryout

12.1 Pipeline batch

1. Sebelum rilis, validasi paket dan freeze seluruh versi konten, rubrik, mapping skor, serta konfigurasi batch.

2. Selama periode berjalan, kumpulkan respons dan exposure dengan timestamp server. Setiap siswa hanya mempunyai satu attempt final untuk paket itu.
3. Saat periode berakhir, tutup batch, finalisasi sesi sesuai aturan tenggat, dan kunci response snapshot. Jawaban terlambat atau upload ulang mengikuti cutoff policy yang sama.
4. Jalankan data quality dan kalibrasi global mixed format. Tentukan item eligible, model fit, uncertainty, serta kecukupan informasi paket.
5. Jika layak, hitung θ_{tryout} global dan skor IRT. Jika gagal sampai batas waktu, tetapkan hasil fallback untuk seluruh batch.
6. Publikasikan hasil, ranking batch, dan seluruh pembahasan secara atomik. Penghitungan serta publikasi selesai paling lambat 3 kali 24 jam setelah periode berakhir.

Item yang kontennya valid tetap dapat gagal gate pengukuran. Sebelum hasil dipublikasikan, Data/AI dapat mengecualikan item bermasalah dari perhitungan IRT untuk seluruh peserta berdasarkan policy yang disahkan. Daftar item berkontribusi tercatat. Jika coverage atau informasi tersisa tidak memadai, seluruh batch memakai fallback; sistem tidak mencampur mode utama antar siswa. Pembahasan semua item yang disajikan tetap tersedia, dengan catatan koreksi bila ada masalah.

Item dengan kunci atau konten invalid tidak boleh tetap menyumbang skor fallback. Koreksi yang dapat diverifikasi sebelum publikasi diterapkan pada seluruh respons batch melalui versi koreksi yang tercatat; item yang tidak dapat diperbaiki dikeluarkan dari penilaian semua peserta. Penyebut nilai rubrik disesuaikan secara konsisten. Jika tidak ada item yang dapat dinilai, hasil menyatakan batch tidak dapat diberi skor, disertai alasan dan pembahasan dengan errata, tanpa membuat angka atau ranking palsu.

12.2 Theta global dan skor utama

θ_{tryout} dihitung dari respons Tryout itu sendiri. Metode estimasi dan prior, bila digunakan, sama untuk seluruh peserta batch; histori Drill tidak menjadi prior personal. Dua peserta dengan pola respons yang identik dalam konteks yang sama memperoleh hasil yang sama. Theta global mengukur kemampuan matematika sesuai paket dan asumsi model, bukan kemampuan universal lintas mata pelajaran.

Skor IRT adalah hasil transformasi monotonik terhadap theta melalui `score_mapping_version` yang disahkan. Pemetaan ke tampilan 0 sampai 100, bila dipilih Product, bukan persentase jawaban benar. Percentile empiris batch disimpan sebagai metrik terpisah. Angka tampilan, pembulatan, batas nilai, dan penanganan respons ekstrem ditentukan sebelum paket dirilis; seluruh benar atau salah tidak boleh menghasilkan infinity yang ditampilkan kepada siswa.

Ranking memakai skor utama pada resolusi yang disahkan dan memberi peringkat sama untuk nilai yang sama. Kecepatan pengerjaan tidak menjadi pengubah theta atau tie-break akademik. Raw score dan poin item tetap disimpan sebagai audit serta feedback konsep. Ringkasan benar atau partial credit per bab boleh ditampilkan, tetapi bukan θ_{tryout} per bab dalam desain ini.

12.3 Hasil dan pembahasan

Sebelum publikasi, siswa melihat status menunggu hasil batch dan jadwal rilis. Setelah publikasi, hasil memuat mode IRT atau fallback, skor, ranking dalam batch, raw score, coverage, serta pembahasan semua soal versi yang dikerjakan. Halaman hasil menjelaskan bahwa nilai merupakan simulasi latihan, bukan nilai TKA resmi.

Kegagalan kalibrasi tidak menahan pembahasan tanpa batas. Sistem menyelesaikan proses batch dengan status IRT tidak tersedia dan rilis fallback pada tenggat. Publish gate memperlakukan IRT yang tidak layak sebagai keputusan fallback yang selesai, bukan sebagai alasan untuk mengulang job selamanya.

12.4 Indikasi tren dan batas interpretasi

Grafik perkembangan memperlihatkan beberapa hasil Tryout beserta batch, mode skor, percentile batch, raw score, dan label difficulty paket bila datanya cukup. Posisi relatif dapat berubah karena peserta, paket, kondisi pengerjaan, dan proses belajar. Selisih angka antarbatch tidak dilabeli kenaikan theta absolut pada satu skala bersama.

Fallback dan IRT tidak disambung sebagai satu seri skor yang dianggap identik. Dashboard memberi penanda mode dan dapat memisahkan seri. Ringkasan beberapa batch adalah indikasi tren belajar, bukan bukti equating. Transformasi tampilan yang sama pada dua model batch tidak menghilangkan batas interpretasi tersebut.

13 Scheduling dan versi aktif

Trigger	Drill	Tryout
Realtime	Simpan respons, item_score, phase_id, assignment trial, dan exposure.	Simpan respons, item_score, dan exposure.
Sesi selesai	Reguler: nilai, XP, dan progres. Trial: evidence tanpa progres.	Finalisasi attempt; hasil akademik menunggu batch.
Harian	Audit ingestion, unique eligible per item, completion, dan kesiapan checkpoint.	Audit completeness serta status deadline batch.
Mingguan atau tambahan evidence	Checkpoint pilot untuk baseline; checkpoint A/B untuk Compare. Monitor original, reference set, dan drift.	Kalibrasi global setelah batch ditutup.
Parameter baru layak	Fase pertama: aktifkan baseline dan referensi layak. Fase kedua: aktifkan hasil dan Compare setelah gate; versi acuan tetap tercatat.	Gunakan versi job final untuk hasil batch; tidak membangun master scale lintas batch.
Periodik	Refresh analitik mastery dan kualitas item atau paket; tanpa reconciliation theta bab.	Analisis kualitas paket dan indikasi tren berlabel.

Cron harian pada PRD diterapkan sebagai ingestion audit, penghitungan responden unik eligible, serta kesiapan checkpoint. Job fase pertama membangun baseline original dan referensi; job fase kedua menjalankan Compare setelah gate tersebut terpenuhi. Drill reguler memperbarui nilai dan progres setelah sesi; pilot serta A/B memperbarui evidence tanpa

progres. Kalibrasi dan aktivasi parameter mengikuti quality gate serta versioning. Hasil Tryout tetap mengikuti penutupan batch dan tenggat publikasi.

Job membawa idempotency key, response_snapshot_id, model_version, dan scoring_policy_version. Retry menggunakan input yang sama. Aktivasi hasil dilakukan melalui transaksi atau mekanisme atomik sehingga dashboard tidak membaca sebagian parameter baru bersama sebagian parameter lama.

14 Kontrak data dan komponen sistem

Entitas	Field minimum
Question dan version	question_id, question_version_id, family_id, parent_question_version_id, chapter_id, subchapter_id, level_id, kompetensi, bentuk, stimulus, opsi, kunci, pembahasan, content_status.
Generation wave	wave_id, template_version, config_version, seed, parameter aktual, target jumlah, iteration, replacement_of, actor dan waktu.
Package dan attempt	package_version_id, package_type, phase_id untuk uji Drill, ecosystem, scale_id atau batch_id, daftar item versi, policy versi, user, timestamp server, session_status, unique attempt key.
Response dan exposure	raw_answer, item_score, maximum_score, fully_correct, missing_or_omission, explanation_viewed_at, prior_item_exposure, prior_family_exposure, eligibility_snapshot, exclusion_reason, exposure_policy_version.
Calibration result	item_version, ecosystem, scale_id bab–subbab–level atau batch_id, model, parameter, uncertainty, unique eligible count, kategori, fit, status, response_snapshot_id, calibration_version.
Variant experiment	experiment_id, phase_id, source_original_calibration_id, arm, assignment_id, class atau cohort, period, original dan candidate version, baseline_version, reference_set_version, config_version, gap atau curve, tolerance_version, evaluator_result, adjustment, stop_reason.
Theta internal dan hasil produk	Trial: theta internal opsional dengan experiment_id, scale_id, SE, dan model_version. Reguler: raw score, mastery, progres. Tryout: theta_tryout, contributing items, estimator_version, score_mapping_version, score_mode, finalization_version.
Audit dan publication	job_id, idempotency key, actor, timestamp, status sebelum dan sesudah, error, deadline, publication_version dan correction reference.
Reference set dan baseline	scale_id, source_original_calibration_id, original_quality_decision, reference_set_version, item_version dan parameter acuan, baseline_version, calibration_version, gate_decision_at, activation_at, stability_result, replacement_link, actor.

Entitas	Field minimum
Trial cohort dan checkpoint	experiment_id atau pilot_id, phase_id, cohort_role, eligibility_policy_version, allocation_policy_version, family_reservation, cutoff, analysis_checkpoint, assigned atau started atau completed atau eligible per fase dan arm A/B, dropout_reason.
Package quality result	package_version_id, blueprint_version, contributing item versions, expected score atau pass probability, method_version, tolerance_version, distribution_status, promotion_reason.

Nama field dapat disesuaikan Software, tetapi hubungan konteksnya wajib dipertahankan. Parameter tidak dicari hanya dengan question_id. Query mengikat versi konten dan rubrik, ecosystem, scale_id bab–subbab–level atau batch_id, serta calibration_version. Pada Drill, phase_id, cohort, source_original_calibration_id, keputusan gate fase pertama, assignment, reference set, baseline, dan configuration snapshot harus dapat ditelusuri untuk setiap keputusan Compare.

Komponen	Tanggung jawab
Generator dan config store	Membuat serta mereproduksi kandidat; menyimpan wave, seed, versi, dan constraint.
Content validator	Memeriksa kunci, solusi, bentuk, duplikat, pembahasan, serta ruang konfigurasi yang disahkan.
Package assembler	Memilih stok produksi atau trial sesuai blueprint, exposure, status, dan tujuan; membekukan paket.
Scoring dan response store	Menghasilkan item_score berversi dan respons idempotent; menyimpan exposure ledger.
Calibration service	Kalibrasi lokal Drill dan theta internal trial; ability Tryout global per batch. Memeriksa identifikasi, kualitas, serta konteks.
Evaluator dan adjuster	Compare pada skala kompatibel, stabilitas original dan referensi, perubahan config terbatas, serta stop condition.
Result publisher	Menetapkan satu mode utama batch, merilis hasil serta pembahasan atomik, menjaga histori.
Trial assignment service	Mengalokasikan cohort pilot dan menyiapkan peserta A/B belum terpapar; memeriksa exposure serta gate fase pertama, mengacak A/B, mempertahankan arm, dan melaporkan completion serta exclusion.

15 Fallback dan integritas historis

Fallback Drill memakai difficulty expert serta mastery dan nilai rubrik. Fallback Tryout memakai nilai rubrik dan ranking batch berbasis nilai tersebut. Label hasil menyatakan IRT belum tersedia beserta alasan yang dapat dipahami. Fallback bukan theta sintetis dan tidak mengisi a, b, atau parameter langkah palsu.

Kondisi	Perilaku sistem
Data kurang atau model tidak converged	Pertahankan parameter belum aktif; Tryout memakai fallback pada tenggat.
Rubrik atau mapping belum disahkan	Blokir rilis item atau paket yang bergantung pada konfigurasi itu.
Konten salah atau ambiguity	Quarantine versi untuk distribusi berikutnya; review dampak pada batch yang belum dipublikasikan.
Item IRT dikeluarkan dari batch	Gunakan daftar eligible yang sama untuk semua peserta; fallback jika informasi atau coverage tidak cukup.
Submit atau job terulang	Deduplicate dengan unique key; satu hasil final dan satu ledger kontribusi.
IRT valid diperoleh sesudah fallback	Tambahkan analitik IRT terpisah dan berversi; jangan mengganti nilai utama atau XP lama.
Kesalahan ditemukan setelah publikasi	Simpan hasil semula dan errata; koreksi administratif memerlukan policy serta catatan revisi, tanpa overwrite diam-diam.
Referensi atau original kontrol tidak stabil	Tahan Compare dan auto-adjust Drill; review acuan, kondisi trial, coverage, serta baseline sebelum trial baru.
Original focal atau reference set belum layak	Tahan respons kandidat dan A/B terkait. Tambah evidence jika kurang; review atau revisi original bila bermasalah, lalu uji versi baru sebelum membentuk baseline.

Pembahasan dan hasil historis selalu memakai versi konten yang benar-benar dikerjakan. Pembaruan parameter, archive, dan regenerate tidak mengubah snapshot tersebut. Ketentuan akses 90 hari untuk pembahasan Drill serta akses pembahasan paket Tryout mengikuti kebijakan PRD.

Hasil batch yang sudah final memiliki score_mode dan versi penilaian tetap. Penambahan analitik post-hoc dibedakan dari penilaian utama. Perubahan model untuk batch baru tidak menghitung ulang nilai atau XP batch lama secara otomatis.

16 Contoh alur terpadu

16 1 Varian PG dalam Drill

Contoh subbab penjumlahan memiliki 50 original yang dibagi menjadi lima level, masing-masing 10 original. Fase pertama menguji original dan calon referensi per level; data tidak digabung menjadi satu skala subbab. Jika setiap original mempunyai dua kandidat, totalnya 100 kandidat, tetapi respons kandidat baru dikumpulkan setelah original focal serta referensi levelnya lolos gate. Uji sedikit kandidat per checkpoint agar respons terkonsentrasi; jumlah dua varian ini ilustrasi, bukan target stok produksi universal.

Sesudah fase pertama Level 2 selesai untuk scope yang dibutuhkan, A memakai sembilan referensi aktif ditambah O; B memakai referensi identik ditambah V1. Peserta A/B belum terpapar seluruh keluarga tersebut. Tabel berikut mengilustrasikan angka pada satu skala lokal yang kompatibel. PASS tetap memerlukan konten, stability, uncertainty, dan toleransi yang disahkan; nilai contoh bukan threshold produksi.

Tahap	Evidence atau tindakan
Pilot original	O dan calon referensi lolos konten, lalu diuji pada fase pertama tanpa varian. Contoh hasil O: a 1,40 dan b 0,50; quality gate tetap diperiksa.
Baseline dan referensi	Original O serta referensi lokal lolos quality gate. Simpan baseline O, reference set, calibration_version, dan uncertainty; bekukan acuan untuk fase kedua.
A/B dan Compare V1	Peserta baru eligible diacak ke referensi + O atau referensi + V1 dengan seed tetap. O kontrol stabil; V1 a 0,85 dan b 1,10. Gap diuji dengan uncertainty dan kurva; D hanya QA pendamping.
Adjustment	Kurangi complexity yang diizinkan dan perbaiki distractor. Simpan config 2, lalu regenerate V2; V1 tetap tersimpan.
Uji V2	Peserta baru eligible mengerjakan trial dengan acuan aktif. V2 a 1,31 dan b 0,64 dibandingkan dengan O kontrol dan baseline yang masih stabil.
Promosi	V2 menjadi READY pada konteksnya bila semua gate item lolos. Gate paket diperiksa terpisah; config 2 tidak otomatis meluluskan kandidat lain.

16 2 Varian dalam Tryout

Batch A memakai original O; setelah periode ditutup, sistem menghitung IRT lokal dan membuka pembahasan O. Batch B memakai varian V yang telah lolos konten serta aturan exposure paket. Respons Batch B menghasilkan parameter V pada skala global Batch B. Selisih b V terhadap b O dari Batch A tidak dipakai untuk menyatakan V lebih sulit secara absolut.

Evaluator memeriksa model fit, uncertainty, respons kategori, dan kualitas V dalam Batch B. Jika layak, V menyumbang theta serta ranking Batch B. Jika tidak, policy mengecualikannya untuk semua peserta atau menetapkan fallback batch. Siswa tetap memperoleh pembahasan

V. Dashboard menampilkan dua hasil sebagai indikasi tren dengan konteks paket dan cohort, bukan sebagai dua titik pada master scale yang telah di-equate.

17 Pengembangan ML untuk konfigurasi generator

ML bukan prasyarat MVP. Rule-based adjustment tetap menjadi baseline sampai histori eksperimen memadai. Dataset eksperimen mencatat range coefficient dan constant, peluang pecahan atau negatif, distractor distance, operation count, solution magnitude, stem length, template, kompetensi, konfigurasi, serta outcome psikometrik yang layak.

Untuk PG, target dapat mencakup gap a dan b terhadap original pada acuan lokal yang kompatibel, kurva respons, serta QA D. Untuk PGK, target mencakup parameter langkah atau representasi kurva skor yang disahkan. Scale_id, level, template, dan konteks eksperimen harus tercatat; parameter absolut dari skala Drill independen atau batch Tryout berbeda tidak dicampur sebagai target difficulty universal. Outcome Tryout lokal dapat mendukung prediksi kualitas khusus konteks.

Ridge atau ElasticNet memberi baseline yang mudah dijelaskan. Random Forest atau Gradient Boosting menangkap hubungan nonlinear. Gaussian Process dan Bayesian Optimization dapat dipertimbangkan ketika trial mahal serta jumlah eksperimen terbatas. Objective menimbang gap pada skala yang kompatibel dan penalti pelanggaran constraint, sambil memperhitungkan uncertainty.

Migrasi dilakukan dari rule, ke rekomendasi ML dalam shadow mode, lalu ke pemilihan config otomatis setelah validasi. Prediksi terbaik tetap harus menghasilkan kandidat yang menjalani validasi konten dan uji respons nyata. Split evaluasi berdasarkan family atau template serta waktu mencegah kebocoran antara turunan yang sangat mirip. Prediksi ML tidak menggantikan bukti kelulusan kandidat.

18 Kesiapan implementasi dan kendali perubahan

18.1 Kriteria penerimaan

ID	Skenario yang harus lolos
AC01	Cold start hanya mengumpulkan original. Respons kandidat dan A/B diblokir sampai original focal lolos gate dan reference set lokal aktif; tidak ada parameter empiris palsu.
AC02	Refresh melanjutkan paket sama; attempt baru memakai varian berbeda dari attempt sebelumnya atau memberi status stok belum tersedia.
AC03	Semua peserta batch Tryout memperoleh paket dan aturan scoring versi yang sama.
AC04	Exposure keluarga focal dan semua referensi dari seluruh modul diperiksa; pengulangan tidak dihitung sebagai responden bersih baru.
AC05	PG dan PGK menggunakan model serta kategori sesuai scoring_policy_version; rubrik belum final memblokir PGK terkait.

Commented [NP6]: AC01 diperbarui untuk memblokir A/B sebelum original focal dan reference set lolos fase pertama; AC21–AC22 melengkapi exposure serta revisi original.

ID	Skenario yang harus lolos
AC06	Compare Drill memakai skala bab–subbab–level kompatibel; skala beda level atau Tryout lintas batch menghasilkan NOT_COMPARABLE.
AC07	INSUFFICIENT tidak memicu adjustment; anomaly menghentikan publikasi otomatis dan masuk review.
AC08	Auto-regenerate berhenti pada batas iterasi; perubahan config tidak mengubah kandidat atau hasil historis.
AC09	Tidak ada theta_profile bab Drill; theta internal tidak memengaruhi skor Tryout. Pola identik dalam batch memberi hasil identik.
AC10	Seluruh peserta batch memakai satu score_mode utama; pengurangan item IRT berlaku konsisten.
AC11	Hasil dan semua pembahasan dirilis bersama paling lambat tenggat, termasuk ketika IRT harus fallback.
AC12	Retry ingestion, submit, atau job tidak menggandakan respons, nilai, XP, dan publikasi.
AC13	Grafik tren membedakan IRT dan fallback serta tidak menyatakan selisih antarbatch sebagai kenaikan theta absolut.
AC14	Revisi item dan parameter mempertahankan akses pada versi konten, scoring, dan hasil lama.
AC15	Pada fase kedua, assignment 1:1 tersimpan pada refresh dan resume; satu peserta tidak menerima kedua arm atau focal satu keluarga dalam trial.
AC16	Trial tidak mengubah XP, bintang, mastery, atau unlock; pembahasannya dirilis setelah collection ditutup.
AC17	Kemampuan kelompok A/B boleh berbeda; identifikasi dan invariance reference set tetap diperiksa sebelum Compare.
AC18	30 peserta unik eligible per item hanya memulai analisis; uncertainty atau coverage buruk menahan CALIBRATED dan PASS.
AC19	Original atau referensi drift menahan Compare dan auto-adjust; versi baseline atau referensi berubah hanya melalui gate dan audit, bukan overwrite acuan eksperimen.
AC20	Item PASS belum berarti paket READY; kandidat baru, seed lain, dan config baru tidak mewarisi kelulusan atau data versi lama.
AC21	Peserta pilot yang sudah terpapar keluarga focal atau salah satu referensi tidak eligible untuk A/B terkait. Eligibility memperhitungkan semua modul; sumber cohort fase kedua direncanakan sebelum pilot.
AC22	Revisi original menghasilkan versi, dataset eligible, dan baseline baru. Data konten berbeda tidak dipool; original gagal bukan target yang harus ditiru generator.

18 2 Konfigurasi yang harus disahkan

Keputusan teknis	Pemilik	Gate dan perilaku sebelum tersedia
Rubrik PGK dan dampak ke produk	Curriculum, Research, PO	Tetapkan penalti MCMA, kategori, bobot, kosong, benar penuh, mastery, bintang, dan XP. Blokir item PGK yang belum lengkap.
Mapping skor IRT dan ranking	PO dan Data/AI	Tetapkan rentang, transformasi, pembulatan, tie, dan respons ekstrem. Wajib tersedia sebelum rilis paket berpenilaian IRT.
Quality gate serta toleransi	Data/AI dan Curriculum	Sahkan precision, fit, invariance, sample, kategori, gap atau kurva, dan kestabilan acuan. Auto-promosi nonaktif sampai policy sah.
Trial dan referensi lokal Drill	Data/AI, Curriculum, PO	Sahkan sampling pilot original, sumber cohort A/B belum terpapar, graf item bersama, gate baseline/referensi, coverage, dan checkpoint. A/B ditahan sampai original focal serta reference set lokal layak.
Ruang generator dan auto-publish	Curriculum dan Data/AI	Sahkan constraint, validator, batas regenerate, dan policy retire. Kandidat di luar ruang tersebut masuk manual review.
Blueprint dan horizon stok	Curriculum, Research, PO	Tetapkan jumlah dan durasi Tryout sesuai kebutuhan resmi yang diverifikasi, coverage, jumlah varian, serta stok rilis. Paket kurang layak ditahan.
Cutoff dan insiden penilaian	PO, Software, Data/AI	Tetapkan sesi melintasi tenggat, delayed response, item invalid, dan koreksi post-publish. Uji bersama deadline 3 kali 24 jam.
Policy trial dan gate paket	PO, Curriculum, Data/AI, Software	Sahkan disclosure, pembahasan trial, blueprint, metode expected score atau peluang mastery, serta toleransi paket. Trial tanpa progres; promosi paket ditahan sampai gate lengkap.

Konfigurasi terbuka tidak diisi dengan asumsi tersembunyi. Pemilik keputusan menetapkan nilai dan tanggal berlaku; Software menerapkannya sebagai versi policy yang dapat ditelusuri. Kesiapan sebuah modul dinilai dari gate yang sudah terpenuhi, sehingga kekosongan konfigurasi tidak berubah menjadi perilaku produk yang ambigu.

18 3 Tanggung jawab dan perubahan rancangan

PO menjaga scope, aturan hasil, serta keputusan perubahan produk. Curriculum dan Research menjaga kompetensi, rubrik, kunci, pembahasan, serta blueprint. Data/AI menjaga identifikasi model, kualitas evidence, konfigurasi generator, dan interpretasi statistik. Software menjaga transaksi, snapshots, scheduling, serta kontrak layanan. QA memverifikasi skenario penerimaan dan failure path.

Pada Tryout, kebutuhan master scale, bank anchor, pre-equating, atau pilot linking khusus merupakan perubahan scope. Gelombang generasi kedua juga belum menjadi fitur MVP. Mode trial A/B Drill pada rancangan ini tidak mengaktifkan fitur tersebut untuk Tryout. Perubahan scope memerlukan rancangan data penghubung, exposure, rilis pembahasan, serta klaim perbandingan yang terpisah.